


Retinanet a lo largo de 30 épocas de entrenamiento

Procesamiento


Se realizó el entrenamiento a 1272 imágenes de animales como: Elefantes, Rinocerontes, Cebras, Búfalos. El procesamiento se realizo en la plataforma GoogleColab. El entrenamiento se desarrollo con la metodología de FineTuning RetinaNet para 30 periodos (*Epoch*), dado el extenso periodo de tiempo que requiere el proceso.

(Gosh, 2025) Gosh, Ankan. FineTuning RetinaNet for Wildlife Detection with PyTorch: A Step-by-Step Tutorial. LearnOpenCV website URL: <https://learnopencv.com/finetuning-retinanet/>

Análisis de resultados del entrenamiento



Ambas métricas aumentan con el tiempo, demostrando que el modelo está aprendiendo a detectar objetos de manera más precisa. El hecho de que la línea roja sea consistentemente más baja que la naranja es normal, ya que la métrica mAP@0.5:0.95 es más exigente. La estabilización de ambas curvas a partir de la época 15 sugiere que el modelo ha convergido y un mayor entrenamiento podría no generar mejoras significativas.



La tendencia general del gráfico es descendente, lo que es un buen indicador de que el modelo está aprendiendo. Hay un pico pronunciado alrededor de la iteración 26, donde la pérdida aumenta de forma abrupta antes de volver a bajar. Este tipo de comportamiento es inusual y el modelo podría estar presentando problemas con la tasa de aprendizaje, problemas con algún lote de imágenes, entre otros.




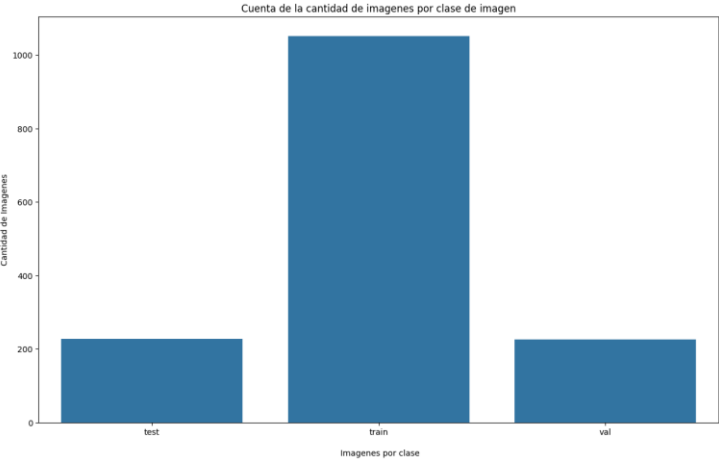
Ambas métricas muestran mejoras significativas en las primeras 5-10 épocas.

Después de la época 15-20, el modelo alcanza una meseta, indicando que el aprendizaje se ha estabilizado. Se podría considerar detener el entrenamiento alrededor de la época 20 para ahorrar recursos.


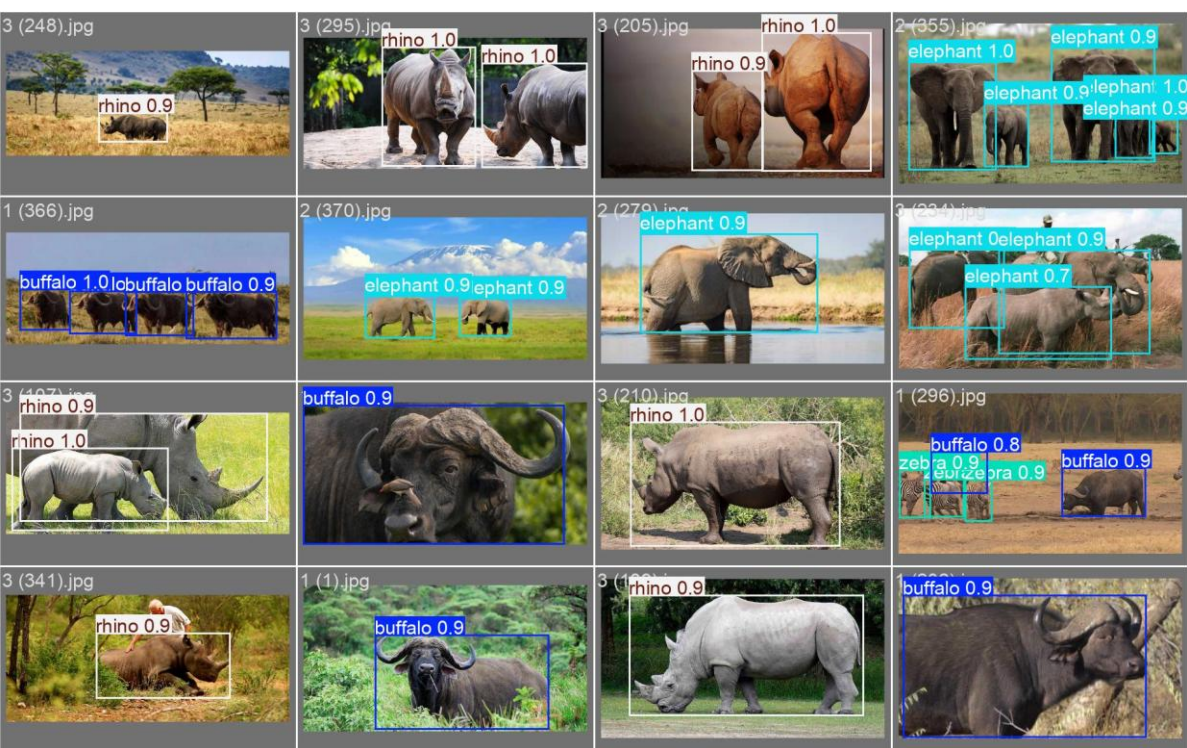
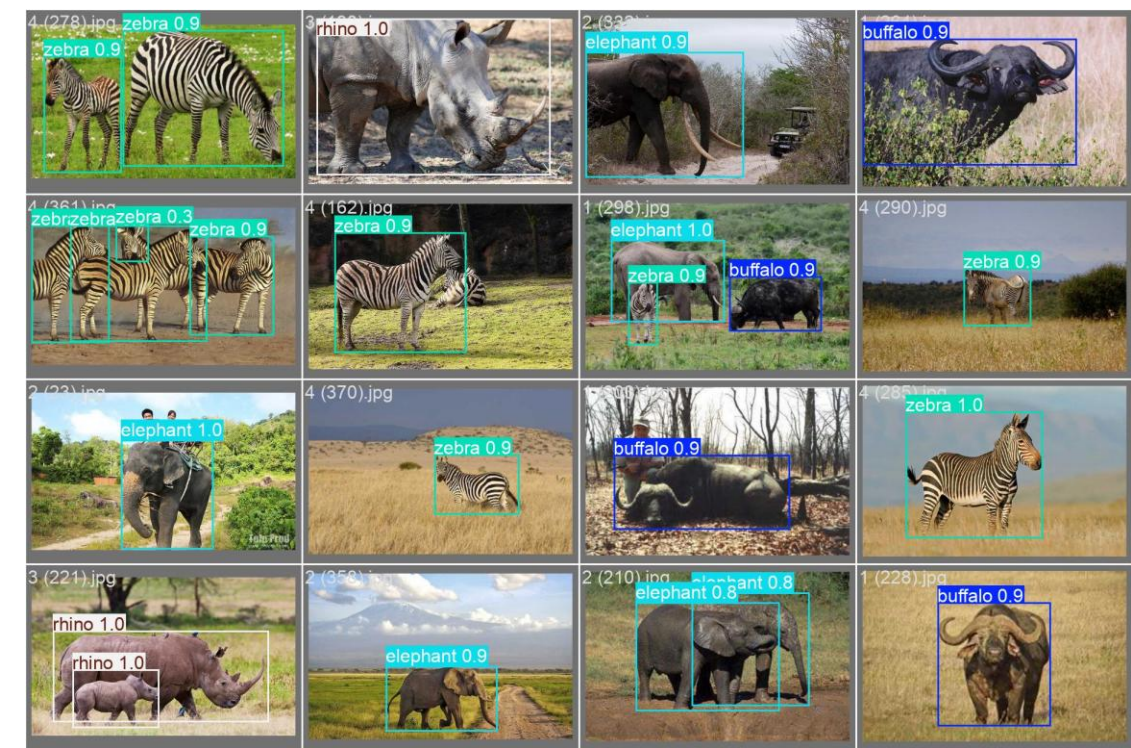
mAP@0.5: El crecimiento se estabiliza después de la época 15, alcanzando un valor cercano a 0.95, lo que sugiere que el modelo ha alcanzado un buen rendimiento en la detección de objetos con una superposición del 50%.

mAP@0.5:0.95: se estabiliza alrededor de la época 15 con un valor de aproximadamente 0.75, lo que sugiere que, si bien el modelo es bueno para localizar objetos (mAP@0.5), tiene más dificultades para lograr una alta precisión en las cajas delimitadoras (mAP@0.5:0.95).

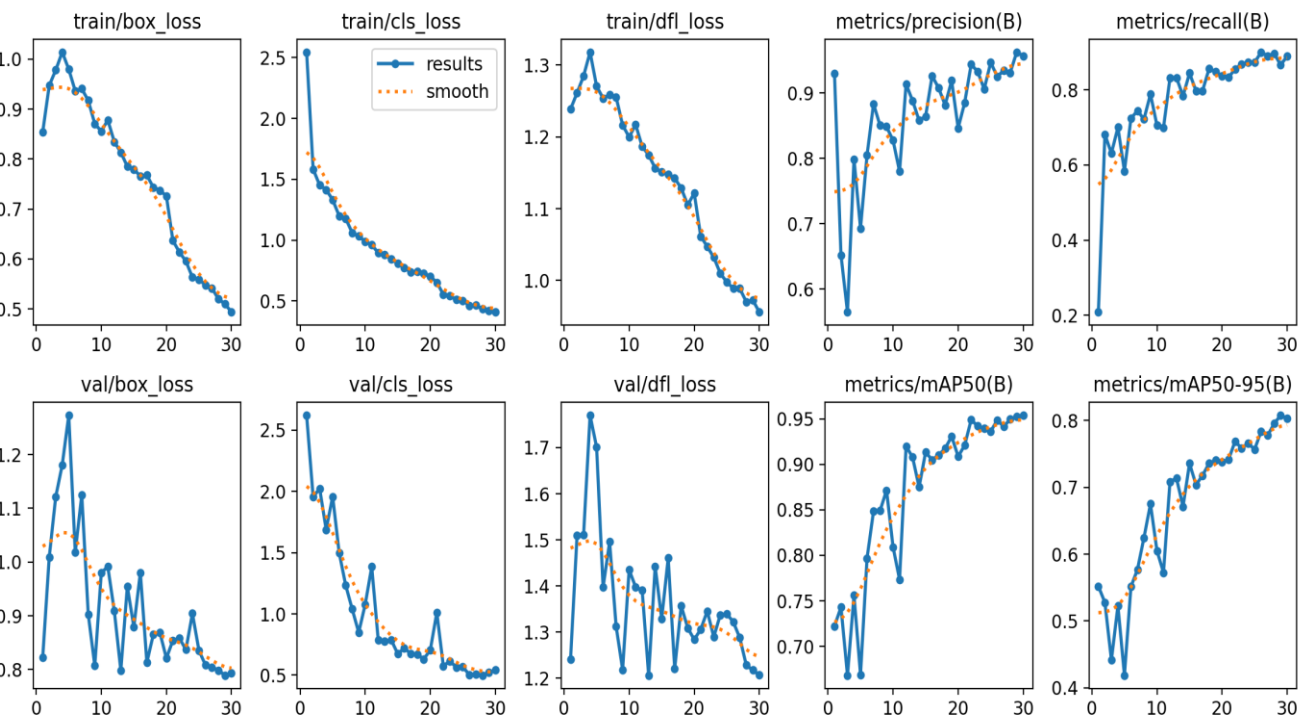
EDA:



Ultralytics -> African Wildlife Dataset

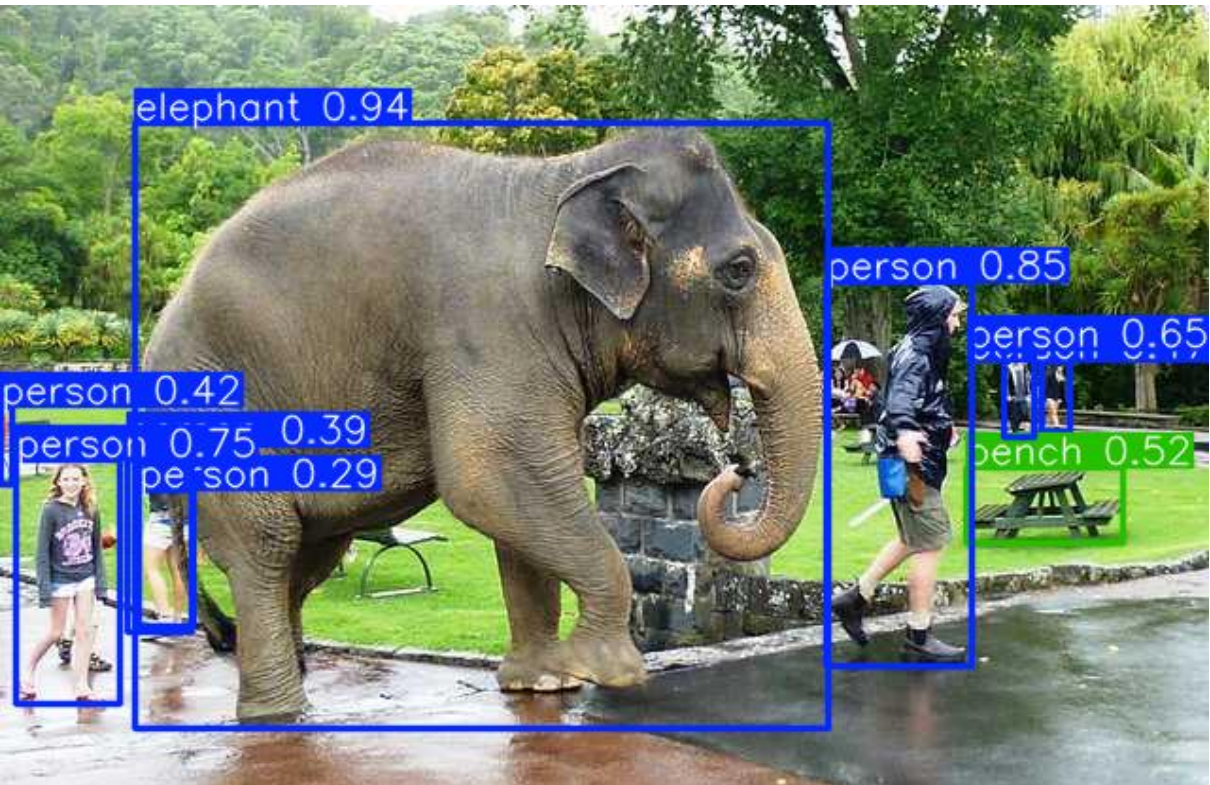


En general, el modelo YOLO está funcionando muy bien en la detección de las clases de animales mostradas. La mayoría de las predicciones correctas se encuentran en la diagonal principal. Sin embargo, hay un problema significativo: el modelo confunde una cantidad considerable de objetos con el fondo. Esto significa que el modelo no solo comete errores de clasificación, sino que también falla en detectar una porción de los objetos de interés.



Las diez curvas demuestran que el modelo se ha entrenado con éxito y de manera robusta. Las pérdidas disminuyen consistentemente y las métricas de rendimiento (precisión, recall, mAP) aumentan de forma constante, lo que indica que el modelo está aprendiendo de manera efectiva. No hay signos evidentes de sobreajuste o de problemas graves de entrenamiento. En resumen, el modelo tiene muy buen rendimiento en la tarea de detección de objetos, tanto en la localización como en la clasificación.

Ultralytics. African Wildlife Dataset. Last Update: 17/03/2025 URL: <https://docs.ultralytics.com/datasets/detection/african-wildlife/>



Reflexión Final:

El entrenamiento con los modelos *FineTuning RetinaNet for Wildlife* y *Ultralytics. African Wildlife Dataset* brindan muy buenos resultados en la identificación de los sujetos, sin embargo, es necesario contar con altos recursos computacionales por el tipo de entrenamiento que se realiza.

Sería sumamente valioso el desarrollar su aplicabilidad en nuestra labor diaria, dado que contamos con recursos de información (*imágenes y videos*) para efectuar los entrenamientos, debido a que no se tiene claridad el como aplicar estos modelos de entrenamiento con nuestra información disponible, por lo que es conveniente, el aplicar y comprender estos modelos de entrenamiento con casos reales y con recursos que se puede poner a disposición. Un ejercicio necesario, es el tomar la información disponible y explorar paso a paso la ejecución y adaptación de ambos modelos.